

Statistique de base pour Data Analyste

Ce cours pose les fondations statistiques indispensables à tout data analyste. Il part des notions fondamentales (population, échantillon, types de variables) pour aller jusqu'aux outils que vous utiliserez quasi quotidiennement dans vos analyses : statistiques descriptives, mesures de position, forme d'une distribution, analyse des variables qualitatives, et tests de normalité. L'objectif n'est pas de former des statisticiens théoriciens, mais des praticiens capables de décrire correctement des données, d'en tirer des interprétations fiables, et de savoir quand une méthode est ou n'est pas appropriée.

Prérequis

- Bases de mathématiques (arithmétique, notion de fonction, pourcentages)
- Notions élémentaires d'algèbre (sommes, moyennes)
- Aisance minimale avec un tableur (Excel/Google Sheets) ou un langage comme Python/R est un plus, mais non obligatoire
- Aucune connaissance statistique préalable n'est requise

Programme détaillé

1. Vocabulaire fondamental : population, échantillon, individu, variable
2. Statistique descriptive vs statistique inférentielle
3. Types de variables : quantitatives et qualitatives
4. Mesures de tendance centrale : moyenne, médiane, mode
5. Mesures de dispersion : variance, écart-type, étendue, coefficient de variation
6. Mesures de position : quartiles, quantiles, IQR et détection des outliers
7. Forme d'une distribution : asymétrie (skewness) et aplatissement (kurtosis)
8. Analyse des variables qualitatives : effectifs, proportions, représentations graphiques
9. Notions d'échantillonnage et d'inférence : p-valeur, intervalle de confiance
10. Tests de normalité : Shapiro-Wilk, Kolmogorov-Smirnov, Q-Q plot
11. Notion de corrélation entre deux variables

Ce que vous apprendrez

À l'issue de ce cours, vous serez capable de distinguer une population d'un échantillon et de comprendre pourquoi cette distinction conditionne toute analyse statistique. Vous saurez identifier le type d'une variable (quantitative continue/discrète, qualitative nominale/ordinaire) et choisir les statistiques adaptées à chacune. Vous maîtriserez le calcul et surtout l'interprétation des mesures de tendance centrale et de dispersion, ainsi que l'utilisation des quartiles et de l'IQR pour détecter des valeurs aberrantes. Vous serez en mesure de décrire la forme d'une distribution (symétrie, aplatissement) et de tester statistiquement si une variable suit une loi normale, une étape clé avant de choisir entre méthodes paramétriques et non paramétriques. Enfin, vous saurez lire et produire les graphiques descriptifs de base (histogramme, boxplot, barplot, pie chart) utilisés dans tout rapport d'analyse de données.

Module 1 — Vocabulaire fondamental : population, échantillon, individu, variable

Avant tout calcul, un data analyste doit maîtriser le vocabulaire de base de la statistique. Ces termes reviennent en permanence et une confusion entre eux peut fausser toute une analyse.

Population

La **population** est l'ensemble complet des individus ou éléments sur lesquels porte une étude. Elle peut être :

- **finie** : par exemple, tous les clients enregistrés d'une boutique en ligne à une date donnée ;
- **infinie ou très large** : par exemple, l'ensemble des transactions futures possibles sur une plateforme.

Étudier une population entière (un **recensement**) est souvent coûteux, long, voire impossible. C'est pourquoi on travaille généralement sur un échantillon.

Échantillon

Un **échantillon** est un sous-ensemble de la population, sélectionné dans le but de représenter cette dernière. L'analyse statistique consiste très souvent à :

1. observer un échantillon (les données dont on dispose réellement) ;
2. en tirer des conclusions généralisables à la population entière.

Pour que ces conclusions soient fiables, l'échantillon doit être **représentatif** de la population, c'est-à-dire ne pas introduire de biais systématique (par exemple, ne pas sur-représenter une tranche d'âge ou une région).

Individu (ou unité statistique)

Un **individu** (ou unité statistique, ou observation) est l'élément de base sur lequel portent les mesures : un client, une transaction, un produit, un pays, un jour, etc. Dans un tableau de données (DataFrame), chaque **ligne** correspond en général à un individu.

Variable

Une **variable** (ou attribut, ou caractère) est une caractéristique mesurée ou observée sur chaque individu : l'âge d'un client, le montant d'un panier, le canal d'achat utilisé. Dans un tableau de données, chaque **colonne** correspond en général à une variable.

Exemple concret (jeu de données e-commerce) :

- Population : l'ensemble des clients d'une plateforme e-commerce.
- Échantillon : les 5 000 clients ayant passé commande sur les 3 derniers mois, extraits dans un fichier CSV.
- Individu : un client (une ligne du tableau).
- Variables : âge, revenu mensuel, montant du panier, note de satisfaction, canal d'achat, etc.

Module 2 — Statistique descriptive vs statistique inférentielle

Il existe deux grandes branches de la statistique, et un data analyste doit toujours savoir dans laquelle il se situe :

- **Statistique descriptive** : elle consiste à résumer, organiser et présenter les données disponibles (sur l'échantillon ou la population), sans chercher à généraliser au-delà des données observées. Moyenne, médiane, écart-type, graphiques, tableaux de fréquences relèvent de la statistique descriptive.
- **Statistique inférentielle** : elle consiste à tirer des conclusions sur une population à partir d'un échantillon, avec une marge d'incertitude quantifiée (intervalles de confiance, tests d'hypothèses, p-valeurs).

La majorité du travail quotidien d'un data analyste (rapports, dashboards, exploration de données) relève de la statistique descriptive. L'inférence intervient dès qu'on veut généraliser un résultat, comparer des groupes de façon rigoureuse, ou valider une hypothèse (A/B testing, tests de normalité, etc.).

Module 3 — Types de variables

Bien identifier le type d'une variable est la première étape de toute analyse : c'est ce type qui détermine les statistiques et les graphiques appropriés.

Variables quantitatives

Une **variable quantitative** prend des valeurs numériques sur lesquelles les opérations arithmétiques ont un sens (addition, moyenne, etc.). On distingue :

- les variables **continues** : elles peuvent prendre une infinité de valeurs dans un intervalle (ex. : revenu mensuel, montant du panier, taille) ;
- les variables **discrètes** : elles ne prennent que des valeurs entières, généralement issues d'un comptage (ex. : nombre d'enfants, nombre de commandes).

Variables qualitatives

Une **variable qualitative** (ou catégorielle) décrit une catégorie ou une modalité, sans valeur numérique directement exploitable arithmétiquement. On distingue :

- les variables **nominales** : les catégories n'ont pas d'ordre naturel (ex. : sexe, produit acheté, canal d'achat, pays) ;
- les variables **ordinales** : les catégories ont un ordre logique (ex. : niveau de satisfaction faible/moyen/fort, tranche de revenu).

Pourquoi cette distinction compte : on ne calcule pas une moyenne sur un canal d'achat (« web », « mobile », « magasin »), mais on peut calculer des effectifs et des proportions. À l'inverse, une moyenne et un écart-type n'ont de sens que pour une variable quantitative.

Module 4 — Mesures de tendance centrale

Les mesures de tendance centrale résument le **niveau moyen** d'une variable quantitative.

Moyenne

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

La moyenne additionne toutes les valeurs et divise par leur nombre. Elle est simple à interpréter mais **sensible aux valeurs extrêmes** (outliers) : un seul client avec un panier à 10 000 \$ peut fortement tirer la moyenne vers le haut.

Médiane

La **médiane** est la valeur qui coupe la distribution en deux parties égales : 50 % des observations lui sont inférieures, 50 % lui sont supérieures. Contrairement à la moyenne, elle est **robuste aux outliers**, ce qui en fait souvent un meilleur indicateur du « client typique » sur des données asymétriques (revenus, montants d'achat).

Mode

Le **mode** est la valeur la plus fréquente dans les données. Il est surtout utile pour les variables discrètes ou qualitatives (ex. : le canal d'achat le plus utilisé), mais peut aussi être calculé pour une variable continue regroupée en classes.

Interprétation combinée

- Si moyenne $\approx$ médiane $\rightarrow$ distribution à peu près **symétrique**.
- Si moyenne nettement $>$ médiane $\rightarrow$ **asymétrie à droite** (quelques valeurs très élevées tirent la moyenne vers le haut).
- Si moyenne nettement $<$ médiane $\rightarrow$ **asymétrie à gauche**.

Cette comparaison rapide moyenne/médiane est un réflexe à avoir systématiquement avant de communiquer un chiffre « moyen » dans un rapport.

Module 5 — Mesures de dispersion

Les mesures de dispersion indiquent **à quel point les valeurs sont étalées** autour de la tendance centrale. Deux jeux de données peuvent avoir la même moyenne tout en étant très différents en pratique si leur dispersion diffère.

Variance

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

La variance mesure la moyenne des écarts au carré par rapport à la moyenne. Le carré rend son unité difficile à interpréter directement (ex. : des « dollars au carré »), d'où l'usage plus fréquent de l'écart-type.

Écart-type

$$s = \sqrt{s^2}$$

L'**écart-type** est la racine carrée de la variance ; il s'exprime dans la même unité que la variable d'origine, ce qui le rend directement interprétable : « le montant du panier varie en moyenne de $\pm X$ \$ autour de la moyenne ».

Étendue

L'**étendue** est simplement $\max - \min$. Simple à calculer, elle est très sensible aux valeurs extrêmes et donne peu d'information sur la répartition globale.

Coefficient de variation (CV)

$$CV = \frac{s}{\bar{x}} \times 100\%$$

Le CV exprime la dispersion **relativement** à la moyenne, ce qui permet de comparer la variabilité de deux variables qui n'ont pas la même échelle (ex. : comparer la dispersion des revenus et celle des montants de panier).

Module 6 — Mesures de position : quartiles, quantiles, IQR et outliers

Quartiles

Les **quartiles** découpent une distribution triée en 4 groupes de même effectif :

- **Q1** (1er quartile) : 25 % des valeurs sont en dessous ;
- **Q2** (médiane) : 50 % des valeurs sont en dessous ;
- **Q3** (3e quartile) : 75 % des valeurs sont en dessous.

Plus généralement, un **quantile** généralise cette idée à n'importe quel pourcentage (déciles, percentiles, etc.).

IQR (écart interquartile)

$$IQR = Q3 - Q1$$

L'IQR représente l'étendue des 50 % « centraux » des données. Il est beaucoup plus robuste aux valeurs extrêmes que l'étendue globale.

Détection des outliers (méthode classique du $1.5 \times IQR$)

$$\text{borne inférieure} = Q1 - 1.5 \times IQR \quad \text{borne supérieure} = Q3 + 1.5 \times IQR$$

Toute observation située en dehors de cet intervalle est considérée comme une **valeur aberrante (outlier)** potentielle. Cette règle est celle visualisée par un **boxplot** (les points affichés hors des « moustaches »).

Bonnes pratiques pour un data analyste :

- un outlier n'est pas nécessairement une erreur : il peut refléter un phénomène réel (un très gros client, une fraude, une promotion exceptionnelle) ;

- toujours investiguer avant de supprimer une observation ;
 - documenter toute décision de traitement des outliers dans un rapport.
-

Module 7 — Forme d’une distribution : asymétrie et aplatissement

Deux indicateurs classiques permettent de décrire la **forme** d’une distribution au-delà de sa tendance centrale et de sa dispersion.

Asymétrie (skewness)

- skewness ≈ 0 → distribution à peu près symétrique ;
- skewness > 0 → **queue à droite** (quelques valeurs élevées étirent la distribution) ;
- skewness < 0 → **queue à gauche**.

Aplatissement (kurtosis)

En version « excess kurtosis » (référence : loi normale = 0) :

- kurtosis ≈ 0 → forme proche de la loi normale ;
- kurtosis > 0 → distribution plus « pointue », avec des queues plus épaisses (plus de valeurs extrêmes que sous une loi normale) ;
- kurtosis < 0 → distribution plus « aplatie » que la normale.

Ces deux indicateurs sont particulièrement utiles avant d’appliquer des méthodes qui supposent la normalité des données (voir Module 9).

Module 8 — Analyse des variables qualitatives

Pour une variable qualitative, les statistiques de tendance centrale et de dispersion classiques ne s’appliquent pas (à l’exception du mode). On utilise à la place :

Effectifs et proportions

- les **effectifs** : nombre d’observations par modalité (ex. : nombre de clients par canal d’achat) ;
- les **proportions** (ou pourcentages) : part de chaque modalité dans l’ensemble.

Représentations graphiques adaptées

- **Diagramme en barres (barplot)** : idéal pour comparer les effectifs ou proportions entre modalités, surtout lorsqu’il y en a plusieurs.
- **Diagramme circulaire (pie chart)** : utile pour visualiser une répartition en parts d’un tout, mais à réserver aux cas avec peu de modalités (au-delà de 5-6 catégories, il devient difficile à lire — préférer un barplot).

Bon réflexe : toujours accompagner un effectif brut de sa proportion (%), qui est en général plus parlante dans un rapport destiné à des décideurs.

Module 9 — Notions d'échantillonnage et d'inférence

Cette section pose les bases nécessaires pour comprendre pourquoi et comment on généralise les résultats d'un échantillon à une population.

Pourquoi échantillonner ?

Il est souvent impossible ou trop coûteux d'interroger toute une population. On extrait donc un échantillon, en veillant à limiter les **biais d'échantillonnage** (sous- ou sur-représentation de certains groupes).

Principales méthodes d'échantillonnage

- **Échantillonnage aléatoire simple** : chaque individu a la même probabilité d'être sélectionné.
- **Échantillonnage stratifié** : la population est divisée en sous-groupes homogènes (strates), puis un échantillon est tiré dans chaque strate, souvent proportionnellement à sa taille.
- **Échantillonnage systématique** : sélection d'un individu tous les k éléments dans une liste ordonnée.
- **Échantillonnage de convenance** : sélection des individus les plus accessibles (rapide, mais risque élevé de biais — à utiliser avec prudence).

P-valeur

La **p-valeur** est la probabilité d'observer un résultat au moins aussi extrême que celui obtenu, en supposant qu'une hypothèse de référence (l'hypothèse nulle H_0) est vraie. Une p-valeur faible (généralement $< 0,05$) suggère que les données observées sont peu compatibles avec H_0 , et conduit à la **rejeter**.

Intervalle de confiance

Un **intervalle de confiance** (par exemple à 95 %) est une plage de valeurs dans laquelle on estime qu'un paramètre de la population (comme une moyenne) se situe, avec un niveau de confiance donné. Il complète une estimation ponctuelle (comme une moyenne d'échantillon) en indiquant l'incertitude associée.

Module 10 — Tests de normalité

De nombreuses méthodes statistiques (tests paramétriques, régressions linéaires, etc.) supposent qu'une variable suit approximativement une **loi normale**. Il est donc essentiel de vérifier cette hypothèse avant de les appliquer.

Test de Shapiro-Wilk

- **H_0** : la variable suit une loi normale ;
- **H_1** : la variable ne suit pas une loi normale.

Lecture de la p-valeur :

- $p\text{-valeur} < 0,05 \rightarrow$ on **rejette H_0** $\rightarrow$ la variable n'est **pas normale** (au seuil de 5 %) ;
- $p\text{-valeur} \geq 0,05 \rightarrow$ on **ne rejette pas H_0** $\rightarrow$ la normalité est **plausible**.

Test de Kolmogorov-Smirnov (KS)

Il compare la distribution observée (généralement standardisée) à une loi normale théorique. Même logique de lecture par la p-valeur : plus elle est faible, plus la distribution observée s'écarte significativement de la normale.

Q-Q plot (quantile-quantile plot)

Le **Q-Q plot** compare visuellement les quantiles de la distribution observée à ceux d'une loi normale théorique :

- si les points suivent globalement une **droite**, la normalité est plausible ;
- si les points s'écartent fortement de la droite (en particulier dans les extrémités/queues), la distribution n'est probablement pas normale.

Règle pratique de décision

En pratique, un data analyste combine plusieurs indices plutôt qu'un seul critère isolé :

- l'allure visuelle des graphiques (histogramme, KDE, Q-Q plot) ;
- les valeurs de skewness et kurtosis (proches de 0) ;
- les p-valeurs des tests de normalité (généralement $> 0,05$).

Si ces trois éléments convergent, on peut raisonnablement approximer la variable par une loi normale et utiliser des méthodes paramétriques ; sinon, on se tourne vers des méthodes non paramétriques, plus robustes aux écarts à la normalité.

Module 11 — Notion de corrélation entre deux variables

Au-delà de l'analyse d'une seule variable (analyse univariée, objet de ce cours), un data analyste est très souvent amené à étudier la relation entre deux variables quantitatives.

Le **coefficient de corrélation de Pearson** mesure la force et le sens d'une relation **linéaire** entre deux variables, sur une échelle de -1 à +1 :

- proche de +1 → forte corrélation positive (les deux variables augmentent ensemble) ;
- proche de -1 → forte corrélation négative (l'une augmente quand l'autre diminue) ;
- proche de 0 → pas de relation linéaire apparente.

Point de vigilance essentiel : corrélation n'implique pas causalité. Deux variables peuvent être corrélées sans qu'il existe de lien de cause à effet direct entre elles (présence possible d'une variable cachée, coïncidence statistique, etc.). Ce point mérite toujours d'être rappelé dans un rapport d'analyse.

Synthèse

Notion	Pour variable quantitative	Pour variable qualitative
Tendance centrale	Moyenne, médiane, mode	Mode uniquement

Notion	Pour variable quantitative	Pour variable qualitative
Dispersion	Variance, écart-type, étendue, CV	Effectifs, proportions
Position	Quartiles, quantiles, IQR, outliers	—
Forme	Skewness, kurtosis	—
Graphiques	Histogramme, KDE, boxplot	Barplot, pie chart
Vérification distributionnelle	Shapiro-Wilk, KS, Q-Q plot	—

Ce socle de statistique descriptive constitue la base sur laquelle s'appuient ensuite les analyses plus avancées : tests d'hypothèses, régressions, A/B testing, et modèles prédictifs. Un data analyste qui maîtrise solidement ces notions dispose des outils nécessaires pour explorer, décrire et communiquer fidèlement ce que racontent les données.